École Nationale Supérieure d'Arts et Métiers Lille

# Rapport Projet Mathématique Statistique

MINA

Modèlisation Statistique

***Élèves :***
Martin Kotlik
Juanita Mesa Londono
Tom Valette

***Enseignants :***
Stephane Clenet



# Table des matières

**I Introduction** **2**
1 Contexte de l'étude . . . 2
2 Contexte du sujet . . . 2
3 Synthèse du déroulement de l'étude . . . 2

**II Analyse préliminaire de la data base** **3**
1 Méthode du maximum de vraisemblance . . . 3
1.1 Estimation de $\mu_{opti}$ . . . 4
1.2 Estimation de $\sigma$ . . . 4
2 Test d'adéquation . . . 5
3 Test d'indépendence . . . 6

**III Conception du modèle statistique de $L$** **7**
1 Regression multiple pour $L$ . . . 7
2 Influence des variables d'entrée sur $L$ . . . 7
3 Réduction de variabilité de $L$ . . . 8

**IV Conception du modèle statistique de $R$** **9**

**V Comparaisons et ciritiques de la modélisation statistique** **10**

# Table des figures

II.1 Détermination des paramètres associés à une distribution normale pour chacunes des données d'entrée . . . 5
II.2 Test d'adéquation d'une loi noramle pour notre jeu de données . . . 6
III.1 Détermination de l'influence de chaque paramètre sur $L$ . . . 7
III.2 Détermination du nombre de paramètres influents nécessaire pour considérer notre modèle pour $L$ . . . 8
III.3 Construction du modèle de $L$ à partir de paramètres non influents . . . 8
III.4 Réduction de la variabilité de $L$ . . . 9
IV.1 Détermination de l'influence de chaque paramètre sur $R$ . . . 9
IV.2 Détermination du nombre de paramètres influents nécessaire pour considérer notre modèle pour $R$ . . . 10
IV.3 Construction du modèle de $R$ à partir de paramètres non influents . . . 10
IV.4 Réduction de la variabilité de $R$ . . . 10

# I Introduction

## 1 Contexte de l'étude

Dans un contexte industriel marqué par la production en grande série et la variabilité intrinsèque des procédés de fabrication, la modélisation des phénomènes physiques à partir de données expérimentales constitue un enjeu majeur. Les approches statistiques permettent, à partir de larges bases de données, d'identifier des relations entre grandeurs mesurées sans nécessairement disposer d'un modèle physique détaillé. Cette démarche s'inscrit dans une logique de modélisation « data-driven », particulièrement adaptée lorsque les systèmes étudiés sont complexes ou partiellement inconnus.

L'utilisation de modèles statistiques, fondés notamment sur des méthodes de vraisemblance, de tests d'hypothèses et de régression, permet ainsi d'estimer les lois de comportement, de quantifier l'influence des paramètres et d'optimiser les performances d'un système. Ces outils sont aujourd'hui largement utilisés dans l'industrie pour le contrôle qualité, la réduction des dispersions et l'amélioration des procédés.

## 2 Contexte du sujet

L'étude porte sur un procédé de fabrication en série de bobines toriques, pour lesquelles certaines grandeurs géométriques et matérielles présentent des dispersions. Ces variations entraînent une variabilité des grandeurs électriques d'intérêt, en particulier l'inductance $L$ ainsi que la résistance $R$. Un échantillon de bobines a ainsi été caractérisé, en mesurant différentes grandeurs telles que la longueur moyenne $l$, la section $S$, l'épaisseur de l'entrefer $e$, la perméabilité relative $v_{rf}$, la section du fil $S_c$ ainsi que la température $T$ .

Il est important de noter que cette base de données est issue d'une phase de mesure préalable, dans laquelle les grandeurs ont été choisies a priori comme pertinentes. Une réflexion amont aurait toutefois consisté à s'interroger sur les variables réellement nécessaires à la modélisation, en s'appuyant notamment sur des considérations physiques du système. Cette distinction met en évidence la complémentarité entre approche statistique et approche physique : la première exploite les données disponibles, tandis que la seconde guide le choix des variables pertinentes.

## 3 Synthèse du déroulement de l'étude

L'étude s'inscrit dans une démarche progressive de modélisation statistique. Dans un premier temps, les différentes grandeurs mesurées sont modélisées comme des variables aléatoires dont on cherche à caractériser la loi de probabilité. Bien que l'hypothèse de normalité soit retenue dans ce travail, d'autres lois auraient pu être envisagées selon la nature des phénomènes étudiés (lois exponentielles, uniformes, etc.).

Une fois les distributions identifiées, des tests statistiques permettent d'évaluer l'adéquation des modèles choisis ainsi que l'indépendance des variables. Cette étape est essentielle pour valider les hypothèses nécessaires à la construction d'un modèle global.

Dans un second temps, une régression multiple est mise en œuvre afin d'établir une relation entre la grandeur d'intérêt et les variables explicatives. L'analyse de ce modèle permet ensuite d'identifier l'influence relative de chaque paramètre sur la réponse étudiée.

Enfin, une étude de la variabilité est réalisée afin de déterminer les contributions des différentes grandeurs à la dispersion de la sortie. Cette analyse permet d'orienter les actions d'amélioration du procédé, en identifiant les paramètres sur lesquels il est le plus pertinent d'agir pour réduire la variabilité des performances.

# II Analyse préliminaire de la data base

Dans le cadre de cette étude, les grandeurs mesurées sur les bobines ne peuvent être considérées comme déterministes en raison des incertitudes liées au procédé de fabrication et aux conditions de mesure. Chaque paramètre (géométrique, matériel ou environnemental) présente ainsi une variabilité intrinsèque, qu'il est nécessaire de modéliser afin de caractériser correctement le comportement global du système.

L'introduction d'un modèle probabiliste pour chacune des variables permet de décrire cette variabilité de manière quantitative. En associant à chaque grandeur une loi de probabilité adaptée, on accède à des informations essentielles telles que la moyenne, la dispersion et la probabilité d'occurrence de certaines valeurs. Ces éléments sont indispensables pour comprendre la distribution des données et pour anticiper le comportement du système en conditions réelles de production.

Afin de poursuivre l'analyse, il est nécessaire de formuler des hypothèses quant au comportement des variables étudiées. Nous faisons ici l'hypothèse que chacune d'elles suit une loi normale. Cette hypothèse sera par la suite évaluée à l'aide d'un test d'adéquation. Cependant, avant de procéder à cette vérification, il convient d'estimer les paramètres associés à ces distributions, à savoir la moyenne $\mu$ et l'écart-type $\sigma$, pour chacune des variables.

## 1 Méthode du maximum de vraisemblance

Ainsi, on décide de procéder à l'identification de la loi de probabilité la plus représentative pour chacunes de nos données d'entrée par la méthode du maximum de vraisemblance. La méthode du maximum de vraisemblance consiste à définir une fonction de vraisemblance $L$, égale au produit des densités de probabilité associées aux observations, et dépendant des paramètres de la loi (ou encore $l = ln(L)$). On cherche ensuite les valeurs de ces paramètres qui maximisent cette fonction.

Comme dit précedemment, on suppose que les observations suivent une loi normale : $X_i \sim \mathcal{N}(\mu, \sigma^2)$.

La densité de probabilité est alors $f(x_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$

On définit alors la fonction de vraisemblance, ou plutôt dans notre cas, la focntion $log-$vraisemblance, associée à une loi normale, pour un échantillon $x_1, x_2, \ldots, x_n$ :

$$\ell(\mu,\sigma) = \ln(\mathcal{L}(\mu,\sigma)) = ln(\prod_{i=1}^{n} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right))$$

d'où

$$\ell(\mu,\sigma) = -\frac{n}{2}\ln(2\pi) - n\ln(\sigma) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2$$

### 1.1 Estimation de $\mu_{opti}$

On dérive :

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)$$

Condition du maximum :

$$\frac{\partial \ell}{\partial \mu} = 0 = \sum_{i=1}^{n}(x_i-\mu) = \sum_{i=1}^{n} x_i - n\mu$$

soit :

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

### 1.2 Estimation de $\sigma$

$$\frac{\partial \ell}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3}\sum_{i=1}^{n}(x_i-\mu)^2$$

Condition du maximum :

$$\frac{\partial \ell}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3}\sum_{i=1}^{n}(x_i-\mu)^2 = 0$$

soit :

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i-\mu)^2$$

En remplaçant $\mu$ par $\hat{\mu}$ :

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i-\hat{\mu})^2$$

L'ensemble de la théorie précédemment expliquée a été appliquée à nos données, reportées dans une feuille de calcul de sorte à les traiter, et dont le résultats est synthétisé ci-joint :

| Méthode MLE | Normale | | | | |
|---|---|---|---|---|---|
| Log-MLE fonction | $\ell(\mu,\sigma) = -(n/2)*\ln(2\pi)-n*\ln(\sigma)-(\sum(yi-\mu)^2)/(2\sigma^2)$ | μ | σ | %μ | %σ |
| S | 2,10E+03 | 1,50E-04 | 6,24E-06 | 2,92E-08 | 2,52E-03 |
| I | 9,47E+02 | 1,88E-01 | 2,07E-03 | 2,34E-08 | 2,53E-03 |
| e | 1,73E+03 | 1,00E-03 | 4,10E-05 | 5,28E-07 | 2,51E-03 |
| vrf | 1,53E+03 | 9,94E-04 | 1,09E-04 | 1,89E-08 | 2,52E-03 |
| T | -5,72E+02 | 2,06E+01 | 4,03E+00 | 4,75E-03 | 6,11E-02 |
| Sc | 3,26E+03 | 1,96E-07 | 1,84E-08 | 0,00E+00 | 0,00E+00 |

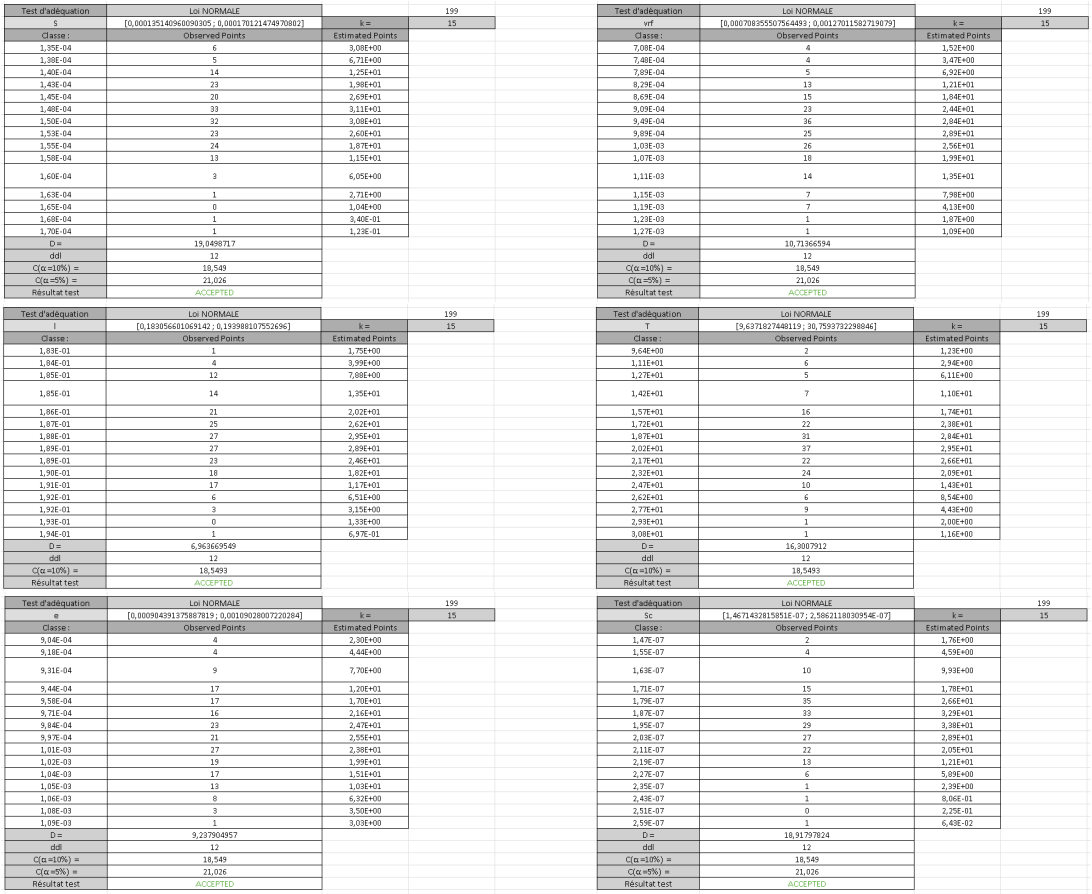
FIGURE II.1 – Détermination des paramètres associés à une distribution normale pour chacunes des données d'entrée

## 2 Test d'adéquation

Comme indiqué précédemment, une fois les paramètres des distributions estimés pour chacune des variables, il convient de vérifier la validité de l'hypothèse selon laquelle celles-ci suivent une loi normale.

Dans ce but, nous mettons en œuvre un test d'adéquation. Ce test repose sur la comparaison entre les fréquences observées dans les données expérimentales et les fréquences théoriques attendues si les variables suivaient effectivement la distribution supposée. Il permet ainsi de juger de la qualité de l'ajustement du modèle probabiliste aux données.

Pour ce, on définit une fonction $D = \sum \frac{(n_k - nf_k)^2}{nf_k}$, qui réalise la comparaison entre la répartition théorique d'une loi (ici normale) et celle de nos données, et qui suit une loi du $\chi^2$, dont on peut comparer la valeur à une seuil de sécurité de sorte a savoir si note hypothèse est validée. Travail réalisé pour toutes nos variables et synthétisé ci-contre :



| Test d'adéquation | Loi NORMALE | | 199 |
|---|---|---|---|
| s | [0,000135140960090305 ; 0,000170121474970802] | k = | 15 |
| Classe : | Observed Points | Estimated Points | |
| 1,35E-04 | 6 | 3,08E+00 | |
| 1,38E-04 | 5 | 6,71E+00 | |
| 1,40E-04 | 14 | 1,25E+01 | |
| 1,43E-04 | 23 | 1,98E+01 | |
| 1,45E-04 | 20 | 2,69E+01 | |
| 1,48E-04 | 33 | 3,11E+01 | |
| 1,50E-04 | 32 | 3,08E+01 | |
| 1,53E-04 | 23 | 2,60E+01 | |
| 1,55E-04 | 24 | 1,87E+01 | |
| 1,58E-04 | 13 | 1,15E+01 | |
| 1,60E-04 | 3 | 6,05E+00 | |
| 1,63E-04 | 1 | 2,71E+00 | |
| 1,65E-04 | 0 | 1,04E+00 | |
| 1,68E-04 | 1 | 3,40E-01 | |
| 1,70E-04 | 1 | 1,23E-01 | |
| D = | 19,0498717 | | |
| ddl | 12 | | |
| C(α =10%) = | 18,549 | | |
| C(α =5%) = | 21,026 | | |
| Résultat test | ACCEPTED | | |

| Test d'adéquation | Loi NORMALE | | 199 |
|---|---|---|---|
| vrf | [0,000708355507564493 ; 0,001270115827190791] | k = | 15 |
| Classe : | Observed Points | Estimated Points | |
| 7,08E-04 | 4 | 1,52E+00 | |
| 7,48E-04 | 4 | 3,47E+00 | |
| 7,89E-04 | 5 | 6,92E+00 | |
| 8,29E-04 | 13 | 1,21E+01 | |
| 8,69E-04 | 15 | 1,84E+01 | |
| 9,09E-04 | 23 | 2,44E+01 | |
| 9,49E-04 | 36 | 2,84E+01 | |
| 9,89E-04 | 25 | 2,89E+01 | |
| 1,03E-03 | 26 | 2,56E+01 | |
| 1,07E-03 | 18 | 1,99E+01 | |
| 1,11E-03 | 14 | 1,35E+01 | |
| 1,15E-03 | 7 | 7,98E+00 | |
| 1,19E-03 | 7 | 4,13E+00 | |
| 1,23E-03 | 1 | 1,87E+00 | |
| 1,27E-03 | 1 | 1,09E+00 | |
| D = | 10,71366594 | | |
| ddl | 12 | | |
| C(α =10%) = | 18,549 | | |
| C(α =5%) = | 21,026 | | |
| Résultat test | ACCEPTED | | |

| Test d'adéquation | Loi NORMALE | | 199 |
|---|---|---|---|
| l | [0,183056601069142 ; 0,193988107552696] | k = | 15 |
| Classe : | Observed Points | Estimated Points | |
| 1,83E-01 | 1 | 1,75E+00 | |
| 1,84E-01 | 4 | 3,99E+00 | |
| 1,85E-01 | 12 | 7,89E+00 | |
| 1,85E-01 | 14 | 1,35E+01 | |
| 1,86E-01 | 21 | 2,02E+01 | |
| 1,87E-01 | 25 | 2,62E+01 | |
| 1,88E-01 | 27 | 2,95E+01 | |
| 1,89E-01 | 27 | 2,89E+01 | |
| 1,89E-01 | 23 | 2,46E+01 | |
| 1,90E-01 | 18 | 1,82E+01 | |
| 1,91E-01 | 17 | 1,17E+01 | |
| 1,92E-01 | 6 | 6,51E+00 | |
| 1,92E-01 | 3 | 3,15E+00 | |
| 1,93E-01 | 0 | 1,33E+00 | |
| 1,94E-01 | 1 | 6,97E-01 | |
| D = | 6,963669549 | | |
| ddl | 12 | | |
| C(α =10%) = | 18,5493 | | |
| Résultat test | ACCEPTED | | |

| Test d'adéquation | Loi NORMALE | | 199 |
|---|---|---|---|
| T | [9,6371827448119 ; 30,7593732298846] | k = | 15 |
| Classe : | Observed Points | Estimated Points | |
| 9,64E+00 | 2 | 1,23E+00 | |
| 1,11E+01 | 6 | 2,94E+00 | |
| 1,27E+01 | 5 | 6,11E+00 | |
| 1,42E+01 | 7 | 1,10E+01 | |
| 1,57E+01 | 16 | 1,74E+01 | |
| 1,72E+01 | 22 | 2,38E+01 | |
| 1,87E+01 | 31 | 2,84E+01 | |
| 2,02E+01 | 37 | 2,95E+01 | |
| 2,17E+01 | 22 | 2,66E+01 | |
| 2,32E+01 | 24 | 2,09E+01 | |
| 2,47E+01 | 10 | 1,43E+01 | |
| 2,62E+01 | 6 | 8,54E+00 | |
| 2,77E+01 | 9 | 4,43E+00 | |
| 2,93E+01 | 1 | 2,00E+00 | |
| 3,08E+01 | 1 | 1,16E+00 | |
| D = | 16,3007912 | | |
| ddl | 12 | | |
| C(α =10%) = | 18,5493 | | |
| Résultat test | ACCEPTED | | |

| Test d'adéquation | Loi NORMALE | | 199 |
|---|---|---|---|
| e | [0,000904391375887819 ; 0,001090280077220284] | k = | 15 |
| Classe : | Observed Points | Estimated Points | |
| 9,04E-04 | 4 | 2,30E+00 | |
| 9,18E-04 | 4 | 4,44E+00 | |
| 9,31E-04 | 9 | 7,70E+00 | |
| 9,44E-04 | 17 | 1,20E+01 | |
| 9,58E-04 | 17 | 1,70E+01 | |
| 9,71E-04 | 16 | 2,16E+01 | |
| 9,84E-04 | 23 | 2,47E+01 | |
| 9,97E-04 | 21 | 2,55E+01 | |
| 1,01E-03 | 27 | 2,38E+01 | |
| 1,02E-03 | 19 | 1,99E+01 | |
| 1,04E-03 | 17 | 1,51E+01 | |
| 1,05E-03 | 13 | 1,03E+01 | |
| 1,06E-03 | 8 | 6,32E+00 | |
| 1,08E-03 | 3 | 3,50E+00 | |
| 1,09E-03 | 1 | 3,03E+00 | |
| D = | 9,237904957 | | |
| ddl | 12 | | |
| C(α =10%) = | 18,549 | | |
| C(α =5%) = | 21,026 | | |
| Résultat test | ACCEPTED | | |

| Test d'adéquation | Loi NORMALE | | 199 |
|---|---|---|---|
| Sc | [1,46714328158516E-07 ; 2,58621180309546E-07] | k = | 15 |
| Classe : | Observed Points | Estimated Points | |
| 1,47E-07 | 2 | 1,76E+00 | |
| 1,55E-07 | 4 | 4,59E+00 | |
| 1,63E-07 | 10 | 9,93E+00 | |
| 1,71E-07 | 15 | 1,78E+01 | |
| 1,79E-07 | 35 | 2,66E+01 | |
| 1,87E-07 | 33 | 3,29E+01 | |
| 1,95E-07 | 29 | 3,38E+01 | |
| 2,03E-07 | 27 | 2,89E+01 | |
| 2,11E-07 | 22 | 2,05E+01 | |
| 2,19E-07 | 13 | 1,21E+01 | |
| 2,27E-07 | 6 | 5,89E+00 | |
| 2,35E-07 | 1 | 2,39E+00 | |
| 2,43E-07 | 1 | 8,06E-01 | |
| 2,51E-07 | 0 | 2,25E-01 | |
| 2,59E-07 | 1 | 6,43E-02 | |
| D = | 18,91797824 | | |
| ddl | 12 | | |
| C(α =10%) = | 18,549 | | |
| C(α =5%) = | 21,026 | | |
| Résultat test | ACCEPTED | | |

FIGURE II.2 – Test d'adéquation d'une loi noramle pour notre jeu de données

Finalement, on trouve que chacunes des varaibles d'entrée peuvent être modéliser par une loi normale dont les paramètres ont été estimés précédemment.

## 3 Test d'indépendence

Le dernier test réside en test d'inter-dépendence de chacunes des variables d'entrée. Les résultats de ces tests permettront de possiblement simplifier notre modèle par quelquechose de plus "simple".

De la même manière que le test d'adéquation, le test d'indépendence évalue une distribution expérimental avec une distribution théorique ...

Pour cela, on construit un tableau de contingence regroupant les effectifs observés pour chaque combinaison de modalités des deux variables. Sous l'hypothèse d'indépendance, on calcule les effectifs théoriques attendus dans chaque case à partir des totaux marginaux. Le test consiste alors à mesurer l'écart entre les effectifs observés et les effectifs attendus à l'aide de la statistique du $\chi^2$, qui somme les écarts quadratiques pondérés. Si cet écart est faible, les différences peuvent être attribuées aux fluctuations aléatoires et l'hypothèse d'indépendance est considérée comme plausible. En revanche, si l'écart est trop important, on rejette cette hypothèse, ce qui indique l'existence d'une dépendance entre les variables.

Pour s'assurer de la validité du test, il est nécessaire de créer des subdivisions "suffi-

semment représentées" avec comme critères au moins 5 effectifs.

Finalement, tous les test d'indépendence on conduit a considérer toutes les variables indépendentes entre elles (la validation de cette hypothèse est d'autant plus appuyé par la valeur du coefficient de détermination $R^2$).

(Vous retrouverez les résultats détaillés de ce test dans le tableur excel associé à ce rapport, dans la feuille "Analyse").

# III Conception du modèle statistique de $L$

Le traitement préliminaire des données d'entrée à principalement conduit à considérer :
- la distribution de chaque variables comme normale avec moyenne et notamment variance connues
- les variables indépendentes entre elles, soit $Cov(X_i, X_j) = 0 \ i \neq j$.

## 1 Regression multiple pour $L$

A présent on souhaite modéliser "correctement" l'impédence $L$ des bobines. Pour ce, on décide d'approximer $L$ par son développement limité, au premier ordre, en fonction de chacunes dse vraibles d'entrée. Pour faire cela, on réalise un regression multiple, qui nous renvoie les coefficients $a_i$ tel que $L = \sum a_i X_i + \epsilon$, avec $\epsilon$ représentant du bruit.
De plus, l'hypothèse d'indépendence précédente, nous permet d'approximer la variance de $L$ par $Var(L) = a_i^2 Var(X_i)$. On peut également introduire $\alpha_i$ tel que $\alpha_i = a_i^2 Var(X_i)/Var(L)$.

De cette manière, $\alpha_i$ permet de mesurer l'influence de la variable $X_i$ sur $L$ ; Cela est particulièrement pertinent pour construire un modèle fiable (cela aussi introduit notamment la notion d'achat/acquisition de certaine données par rapport a d'autre).

Dès lors, nousa vons pu déterminer les paramètres les plus influent sur la mesure d'impédance $L$ :

| L(S,l,e,vrf,T,Sc) | | | | | | | | Ordre influence : décroissant |
|---|---|---|---|---|---|---|---|---|
| L = | a1*S | a2*l | a3*e | a4*vrf | a5*T | a6*Sc | + b | S |
| ai | 419,430623 | -0,04591283 | -53,5413421 | -10,071746 | 8,18755E-07 | -1176,13106 | 0,07313267 | e |
| $R^2$ | 0,99731982 | | | | | | | vrf |
| αi_exp | 4,50E-01 | 5,93E-04 | 3,17E-01 | 7,85E-02 | 7,14E-07 | 3,07E-05 | | l |
| (Σαi)exp | 8,46E-01 | | | | | | | Sc |
| Σαi | 1,00E+00 | | | | | | | T |
| hyp : | Cov(Xi,Xj) ≈ 0 | | | | | | | |
| | donc, bruit non nul | | | | | | | |

FIGURE III.1 – Détermination de l'influence de chaque paramètre sur $L$

On relève notamment que, contrairement à la théorie, $\sum \alpha_i \neq 1$, ce qui met en lumière la présence de bruit sur nos mesures, ce qui représente un axe d'amélioration de notre modèle.

## 2 Influence des variables d'entrée sur $L$

On décide alors de tracer $R$ en fonction de "l'affinage" de notre modèle en considérant successivement plus ou moins de paramètres influents (voir feuille de calcul).

| Index | Ri |
|---|---|
| 1 | 0,76762601 |
| 2 | 0,95906597 |
| 3 | 0,99836758 |
| 4 | 0,99864359 |
| 5 | 0,99865861 |
| 6 | 0,99865891 |

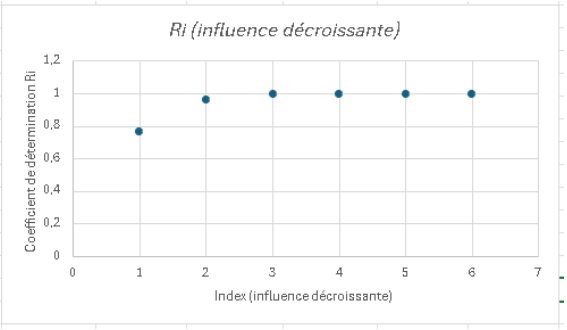



FIGURE III.2 – Détermination du nombre de paramètres influents nécessaire pour considérer notre modèle pour $L$

Ces résultats nous permettent de considérer notre modèle "viable" à partir de 3 variables influents, c'est à dire, que note modèle est suffisament fonctionnel en considérant que $L(S, e, v_{rf})$.

| Index | Ri |
|---|---|
| 6 | 0,02379408 |
| 5 | 0,07025441 |
| 4 | 0,1400438 |
| 3 | 0,3581928 |
| 2 | 0,74886121 |
| 1 | 0,99865891 |

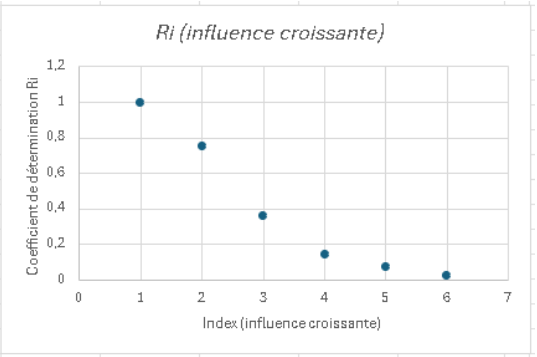



FIGURE III.3 – Construction du modèle de $L$ à partir de paramètres non influents

Ce graphe souligne l'importance de sélectionner des variables pertinentes lors de la construction d'un modèle statistique. On constate que le modèle n'acquiert une qualité satisfaisante que lorsqu'il intègre des paramètres fortement influents. À l'inverse, un modèle reposant uniquement sur des variables de faible influence présente des performances limitées, et son amélioration reste marginale, même en augmentant le nombre de ces variables.

## 3 Réduction de variabilité de $L$

Dans un dernier temps, nous cherchons à identifier les grandeurs pour lesquelles une amélioration de la précision de mesure permettrait de réduire la variabilité du modèle. D'après les résultats précédents, l'inductance peut être modélisée à partir des variables les plus influentes, soit $L = f(S, e, v_{rf})$. En s'appuyant sur la fiabilité du modèle, la variance de $L$ peut être approximée par :

$$Var(L) = a_1^2 Var(S) + a_2^2 Var(e) + a_3^2 Var(v_{rf})$$

Cette relation met en évidence la contribution de chaque variable à la variabilité totale de $L$ et permet ainsi d'identifier les paramètres sur lesquels il est prioritaire d'agir pour améliorer la précision globale du modèle.

On introduit alors des coefficients $k_i$ représentant les facteurs de réduction de la variabilité de chaque variable $X_i$. On obtient ainsi l'expression suivante :

$$Var(L) = a_1^2 \frac{Var(S)}{k_1} + a_2^2 \frac{Var(e)}{k_2} + a_3^2 \frac{Var(v_{rf})}{k_3}$$

Cette formulation permet d'estimer les valeurs des coefficients $k_i$ nécessaires pour atteindre un objectif de réduction de la variabilité de $L$. En pratique, ces coefficients traduisent le niveau d'amélioration requis sur la précision des mesures de chaque variable. Dans notre étude, l'objectif fixé consiste à réduire la variabilité de $L$ de 50%.

| | Réduction de variabilité | | | |
|---|---|---|---|---|
| | Var(L) = | a1².Var(S)/k1 | a2².Var(e)/k2 | a3².Var(vrf)/k3 |
| | ai | 419,3237096 | -53,22519579 | -9,976006015 |
| | Var(L)_init | 1,52358E-05 | Var(L)_exp | 1,29E-05 |
| 1 | ki | 15 | | |
| | ΔVar(L) [%] | 49,99% | | |
| 2 | ki | 2 | 3 | |
| | ΔVar(L) [%] | 51,63% | | |
| 3 | ki | 2 | 2 | 2 |
| | ΔVar(L) [%] | 50,00% | | |

FIGURE III.4 – Réduction de la variabilité de $L$

On obtient ses résultats dichotomiquement. On retrouve que précision de notre modèle est grandement améliorer en améliorant la précision de mesures des paramètres les plus influents.

# IV Conception du modèle statistique de $R$

Comme pour l'impédance $L$, on réalise l'ensemble des étapes précedemment décrites, pour concevoir un modèle statistique fiable pour $R$. L'ensemble des résultats pertinents sont synthétisées ci-contre (pour plus de précision, voir feuille de calcul) :

| R(S,l,e,vrf,T,Sc) | | | | | | | |
|---|---|---|---|---|---|---|---|
| R = | a1*S | a2*l | a3*e | a4*vrf | a5*T | a6*Sc | + b |
| ai | 2687,237564 | 0,550845742 | 32,75555873 | 9,43753175 | -0,00036835 | -4372890,5 | 1,172882 |
| R² | 0,983926017 | | | | | | |
| αi_exp | 3,95E-02 | 1,83E-04 | 2,53E-04 | 1,47E-04 | 3,09E-04 | 9,08E-01 | |
| (Σαi)exp | 9,48E-01 | | | | | | |
| Σαi | 1,00E+00 | | | | | | |
| hyp : | Cov(Xi,Xj) ≈ 0 | | | | | | |
| | donc, bruit non nul | | | | | | |

| Ordre influence : décroissant |
|---|
| Sc |
| S |
| T |
| e |
| l |
| vrf |

FIGURE IV.1 – Détermination de l'influence de chaque paramètre sur $R$

| Index | Ri |
|---|---|
| 1 | 0,9716396 |
| 2 | 0,991497625 |
| 3 | 0,991569905 |
| 4 | 0,991687661 |
| 5 | 0,991757334 |
| 6 | 0,991827469 |

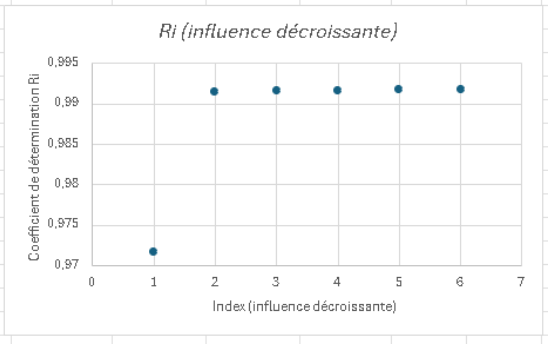



FIGURE IV.2 – Détermination du nombre de paramètres influents nécessaire pour considérer notre modèle pour $R$

| Index | Ri |
|---|---|
| 6 | 0,00635301 |
| 5 | 0,10727566 |
| 4 | 0,10728393 |
| 3 | 0,10766709 |
| 2 | 0,298853 |
| 1 | 0,99182747 |

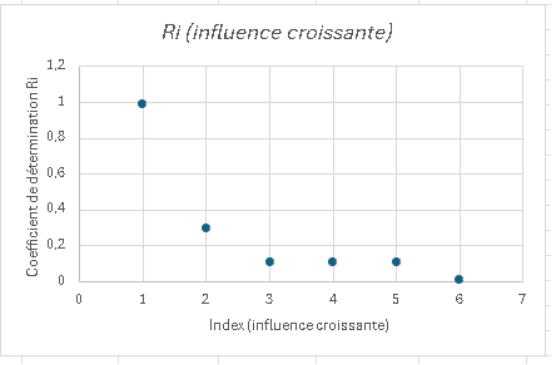



FIGURE IV.3 – Construction du modèle de $R$ à partir de paramètres non influents

| | Réduction de variabilité | | | |
|---|---|---|---|---|
| | Var(L) = | $a1^2$.Var(Sc)/k1 | $a2^2$.Var(S)/k2 | |
| | ai | -4380764,988 | 2673,156648 | |
| | Var(L)_init | 0,007128185 | Var(L)_exp | 0,006774562 |
| 1 | ki | 2 | | |
| | ΔVar(L) [%] | 47,93% | | |
| 2 | ki | 1 | 2 | |
| | ΔVar(L) [%] | 50,00% | | |

FIGURE IV.4 – Réduction de la variabilité de $R$

# V Comparaisons et ciritiques de la modélisation statistique

Ce projet a permis de mettre en œuvre une démarche complète de modélisation statistique appliquée à un système physique réel, en l'occurrence une bobine torique. À partir de données expérimentales, nous avons construit des modèles reliant les grandeurs électriques d'intérêt, l'inductance $L$ et la résistance $R$, aux paramètres géométriques et matériels du système.

L'approche statistique adoptée présente plusieurs avantages. Elle permet, sans connaissance détaillée du système physique, d'identifier les variables les plus influentes, de quantifier leur impact sur la réponse et de proposer des axes d'amélioration du procédé, notamment en termes de réduction de la variabilité. De plus, les modèles obtenus offrent une très bonne qualité d'ajustement, comme en témoigne la valeur élevée du coefficient de détermination $R^2$.

Cependant, cette approche présente également certaines limites. Le modèle statistique repose sur des hypothèses (dans note cas : normalité, indépendance des variables, linéarité locale) qui ne traduisent pas nécessairement la réalité physique du système. De plus, il reste fortement dépendant des données disponibles : un changement de domaine d'utilisation ou de conditions de fonctionnement peut remettre en cause sa validité. Par ailleurs, l'interprétation physique des coefficients du modèle reste limitée.
En comparaison, un modèle physique repose sur des lois fondamentales bien établies.

Par exemple, l'inductance d'une bobine torique peut être approximée par :

$$L = \frac{N^2}{R_{tot}} = \frac{N^2}{\frac{l}{v_0 v_{rf} S} + \frac{e}{v_0 S}} = \frac{v_0 v_{rf} N^2 S}{l + e.v_{rf}}$$

avec $R$ reluctance magnétique.

et la résistance électrique par :

$$R = \rho(T).\frac{l_f}{S_c}$$

avec $\rho$ résistivité du fil (propre au matériau).

Ces relations offrent une compréhension directe des phénomènes en jeu et permettent une extrapolation à des situations non observées expérimentalement. Elles mettent également en évidence les paramètres dominants de manière cohérente avec les résultats statistiques obtenus.

Ainsi, l'étude met en évidence la complémentarité des deux approches. Le modèle statistique constitue un outil puissant pour exploiter les données expérimentales, identifier les paramètres influents et optimiser un procédé industriel. En revanche, le modèle physique apporte une interprétation des résultats et une capacité de généralisation essentielle.

En conclusion, l'utilisation conjointe de ces deux approches apparaît comme la stratégie la plus pertinente : la physique permet de guider la modélisation et d'en garantir la cohérence, tandis que la statistique permet d'exploiter efficacement les données pour améliorer les performances du système.

# Références